

Comparación Variables

$$Y_i = \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_n X_{in} + \epsilon_i$$

$\epsilon_i \sim N(0, \sigma^2)$

$$Y_i^* = \frac{Y_i - \bar{Y}}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

$$X_i^* = \frac{X_i - \bar{X}}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}}$$

Difere un poco de las notas de clase

Selección modelos

(1). Minimizar C_p

$$C_p = \frac{SSE_p}{MSE} - (n-2p)$$

(2). Minimizar $PRESS_{adj}$

$$PRESS_{adj} = \sum_{i=1}^n e_{oi}^2$$

(3). Maximizar R_p^2

(4). Maximizar R_{adj}^2

(5). Minimizar SSE_p (MSE)

Según el principio parsimonia

Criterios multicolinealidad

$$VIF_j = \frac{1}{1 - R_j^2}$$

• $VIF_j \leq 5$ no hay mult.
 $5 < VIF_j < 10$ moderada
 $VIF_j \geq 10$ severa

R_j^2 : Variancia que es explicada por el grado de asociación lineal entre la variable X_j y las demás variables en general $X_i \sim \dots$

$$X_j = \beta_0 + \beta_1 X_{j1} + \dots + \beta_{j-1} X_{j,j-1} + \beta_{j+1} X_{j,j+1} + \dots + \beta_n X_{jn} + \epsilon_j$$

índice de condición: Descomposición en valores propios

$$K_j = \frac{\lambda_{\max}}{\lambda_j}$$

$10 > \sqrt{K_j}$ No hay multicol.
 $10 \leq \sqrt{K_j} < 31,6$ moderada
 $\sqrt{K_j} \geq 31,6$ severa

Número condición: Último índice condición (más grande)

Proporción de varianza explicada $\pi_{ij} > 0,5$

• VIF_j , 1 condición, # cond: Detectar si hay o no hay multicolinealidad y en qué grado

• π_{ij} : Identificar el conjunto de variables que causan la mult.

Métodos Selección Variables

Forward: $Y_i = \beta_0 + \epsilon_i \Rightarrow Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_n X_{in} + \epsilon_i$

Backward: $Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_n X_{in} + \epsilon_i \Rightarrow Y_i = \beta_0 + \epsilon_i$

Stepwise: Combinación: Bidireccional

Modelos con variables indicadoras c : # categorías

(1). Modelo sencillo: $Y_i = \beta_0 + \beta_1 \Pi_{i1} + \beta_2 \Pi_{i2} + \dots + \beta_c \Pi_{ic} + \epsilon_i$; $\epsilon_i \sim N(0, \sigma^2)$

• Solo cambia el intercepto; rectas horizontales

(2). Modelo con variable continua:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 \Pi_{i2} + \beta_3 \Pi_{i3} + \dots + \beta_c \Pi_{ic} + \epsilon_i$$

$\epsilon_i \sim N(0, \sigma^2)$

(Tomando a la primera categoría Π_{i1} como referencia)

sin interacciones:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 \Pi_{i2} + \beta_3 \Pi_{i3} + \dots + \beta_c \Pi_{ic} + \epsilon_i$$

$\epsilon_i \sim N(0, \sigma^2)$

(Tomando a la última categoría Π_{ic} como ref.)

• Solo cambia el intercepto; rectas no paralelas

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \epsilon_i; \epsilon_i \sim N(0, \sigma^2)$$

Tomando la última categoría como ref.

• Solo cambia el intercepto; rectas con pendiente

(3). Modelo con variable continua $Y_i = [\beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_c X_{ic}] + 1 [\beta_{c+1} X_{i1} X_{i2} + \dots + \beta_{2c} X_{i1} X_{ic}] + \epsilon_i$
y con interacciones:

Parte 1: Modelo (2)

Parte 2: Interacción

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i1} X_{i2} + \beta_5 X_{i1} X_{i3} + \epsilon_i$$

Tomando X_{i1} como categoría referencia.

• Cambia el intercepto y la pendiente

Ejemplo importante: Método de todas las regresiones posibles

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i1} X_{i2} + \beta_5 X_{i1} X_{i3} + \epsilon_i; \epsilon_i \sim N(0, \sigma^2) : \text{Modelo completo (MF)}$$

tabla todas regresiones posibles

k	R_sq	adj_R_sq	SSE	Cp	Variables_in_model
1	0.270	0.266	6888439489	22.111	bore
2	0.186	0.181	8339332596	67.331	bore:bodyStySedan
3	0.077	0.072	8607903816	75.264	bodyStySedan
4	0.080	-0.085	9324673834	96.436	bodyStyWagon
5	0.080	-0.086	9325424921	96.459	bore:bodyStyWagon
6	0.323	0.315	6313303524	9.485	bore
7	0.316	0.309	6375515576	11.323	bore:bodyStySedan
8	0.299	0.291	6537854051	16.118	bodyStySedan
9	0.278	0.270	6737360745	22.011	bore
10	0.277	0.269	6746166218	22.271	bore:bodyStyWagon
11	0.127	0.117	8145559383	63.607	bodyStySedan
12	0.124	0.114	8169682089	64.320	bodyStyWagon
13	0.092	0.082	8465835217	73.044	bodyStySedan
14	0.090	0.080	8485828856	73.658	bodyStyWagon
15	0.013	0.002	9206352559	94.941	bodyStyWagon
16	0.355	0.344	6017124167	2.736	bore
17	0.324	0.312	6308226252	11.335	bore:bodyStySedan
18	0.323	0.312	6310049522	11.389	bodyStySedan
19	0.316	0.305	6373069292	13.277	bore:bodyStyWagon
20	0.316	0.305	6374072360	13.307	bodyStyWagon
21	0.314	0.303	6394885452	13.898	bore:bodyStySedan
22	0.312	0.300	6415771091	14.512	bodyStySedan
23	0.283	0.271	6690547232	22.628	bore:bodyStyWagon
24	0.137	0.122	8051360814	62.825	bodyStyWagon
25	0.103	0.088	8367499581	72.163	bodyStySedan
26	0.357	0.343	5992519891	4.018	bore
27	0.357	0.343	5993138370	4.028	bore:bodyStySedan
28	0.327	0.311	6297449816	12.518	bodyStySedan
29	0.325	0.310	6297449816	13.017	bodyStyWagon
30	0.320	0.305	6337833534	14.210	bore:bodyStySedan
31	0.357	0.339	5992191967	6.000	bore:bodyStyWagon

$$H_0: \beta_2 = 0$$

$$H_1: \beta_2 \neq 0$$

• Modelo reducido:
Reemplazar H_0 en MF: MR.

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_3 X_{i3} + \beta_4 X_{i1} X_{i2} + \beta_5 X_{i1} X_{i3} + \epsilon_i$$

$$F = \frac{[SSR(MR) - SSR(MF)] / v}{MSE(MF)} \sim f_{v, n-p}$$

• Bore (X_{i1}); Sedan (X_{i2}); Wagon (X_{i3}); Bore: Sedan ($X_{i1} \cdot X_{i2}$); Bore: Wagon ($X_{i1} \cdot X_{i3}$)

• Bore (X_{i1}); Wagon (X_{i3}); Bore: Sedan ($X_{i1} \cdot X_{i2}$); Bore: Wagon ($X_{i1} \cdot X_{i3}$)

$$F = \frac{16280574850 - 5992191967 / 1}{5992191967 / 176}$$

(1). 177 gl
(2). 176 gl